

Сэмплирование Томпсона

Байесовский подход к задаче многоруких бандитов

Дилемма Exploration vs. Exploitation

Представьте, что вы находитесь в казино перед рядом игровых автоматов — «одноруких бандитов». Каждый автомат имеет свою, неизвестную вам, вероятность выигрыша. У вас есть ограниченное количество жетонов. Ваша цель — максимизировать суммарный выигрыш.

Перед вами встаёт фундаментальная дилемма:

- **Exploration (исследование):** пробовать разные автоматы, чтобы узнать их вероятности выигрыша.
- **Exploitation (использование):** играть на том автомате, который пока кажется лучшим, чтобы получить максимальную награду.

Эта задача формализуется как **задача многоруких бандитов (Multi-Armed Bandit, MAB)**. Она возникает повсюду: А/В-тестирование сайтов, клинические испытания, выбор рекламных баннеров, рекомендательные системы.

Помогут темы курса

- **Критерий Брусса** — задача оптимальной остановки: «когда прекратить поиск и принять решение?»
- **Критерий Кэлли** — оптимальный размер ставки при известной вероятности: «сколько поставить?»
- **Индекс Гиттинса** — точное оптимальное решение для дисконтированных бандитов: «какой рычаг выбрать?»
- **Метод первого шага** — декомпозиция ожидания через первое действие
- **Смешанные распределения** — предсказательное распределение как смесь по апостериорному
- **Максимальная энтропия** — выбор неинформативного априорного распределения

Формальная постановка задачи MAB

Пусть имеется K рычагов (действий, «arms»). На каждом шаге $t = 1, 2, \dots, T$:

1. Агент выбирает рычаг $A_t \in \{1, \dots, K\}$
2. Среда генерирует награду $R_t \sim P_{A_t}$, где P_k — неизвестное распределение наград для рычага k .

Обозначим истинное математическое ожидание награды k -го рычага: $\mu_k = \mathbb{E}[R_t \mid A_t = k]$ Пусть $\mu^* = \max_k \mu_k$ — математическое ожидание лучшего рычага, $k^* = \arg \max_k \mu_k$ — оптимальный рычаг

Кумулятивный regret

Сожаление за T шагов — это разность между суммарной наградой оптимальной стратегии (всегда выбирать k^*) и суммарной наградой алгоритма:

$$\text{Regret}(T) = T \cdot \mu^* - \sum_{t=1}^T \mu_{A_t} = \sum_{t=1}^T (\mu^* - \mu_{A_t})$$

Заметим, что $\text{Regret}(T) \geq 0$ всегда. Цель — минимизировать ожидаемый regret $\mathbb{E}[\text{Regret}(T)]$

Связь с методом первого шага

Вспомним : $\mathbb{E}[X] = \sum_i \mathbb{E}[X | A_1 = i] \mathbb{P}(A_1 = i)$. Применим аналогичную идею декомпозиции к regret. Обозначим $N_{k(T)} = \sum_{t=1}^T \mathbb{1}[A_t = k]$ — число выборов рычага k за T шагов. Тогда:

$$\text{Regret}(T) = \sum_{k=1}^K \Delta_k \cdot N_{k(T)}$$

где $\Delta_k = \mu^* - \mu_k \geq 0$ — **субоптимальность** рычага k . Взяв математическое ожидание:

$$\mathbb{E}[\text{Regret}(T)] = \sum_{k=1}^K \Delta_k \cdot \mathbb{E}[N_{k(T)}]$$

Таким образом, задача минимизации regret сводится к минимизации $\mathbb{E}[N_{k(T)}]$ для субоптимальных рычагов. Хороший алгоритм должен быстро «понять», что рычаг k субоптимален, и перестать его выбирать.

Байесовский подход и Beta-Bernoulli модель

Для простоты рассмотрим случай **бинарных наград**: $R_t \in \{0, 1\}$ (выигрыш или проигрыш). Тогда P_k — это распределение Бернулли с неизвестным параметром $\theta_k \in [0, 1]$:

$$\mathbb{P}(R_t = 1 | A_t = k, \theta_k) = \theta_k$$

В байесовской статистике неизвестный параметр θ_k рассматривается как **случайная величина** с некоторым распределением. Нам нужно задать для неё **априорное распределение** (prior) $\pi(\theta_k)$, отражающее наши знания до наблюдения данных.

Принцип максимальной энтропии

Какое распределение выбрать для $\theta_k \in [0, 1]$, если мы ничего не знаем о рычаге? Мы ищем распределение $\pi(\theta)$, максимизирующее дифференциальную энтропию:

$$\max H(\theta) = - \int_0^1 \pi(\theta) \ln \pi(\theta) d\theta$$

при единственном ограничении нормировки $\int_0^1 \pi(\theta) d\theta = 1$

Записываем лагранжиан: $\mathcal{L}[\pi] = - \int \pi \ln \pi d\theta - \lambda (\int \pi d\theta - 1)$. Вариационная производная: $\delta_{\frac{\mathcal{L}}{\delta}} \pi = - \ln \pi - 1 - \lambda = 0$, откуда $\pi(\theta) = e^{-1-\lambda} = \text{const}$. Нормировка даёт $\pi(\theta) = 1$ для $\theta \in [0, 1]$. Равномерное распределение является частным случаем **Бета-распределения**: $\text{Uniform}(0, 1) \equiv \text{Beta}(1, 1)$.

Бета-распределение

Случайная величина θ имеет **Бета-распределение** $\text{Beta}(\alpha, \beta)$ с параметрами $\alpha, \beta > 0$, если её плотность:

$$\pi(\theta \mid \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}, \quad \theta \in [0, 1]$$

Математическое ожидание: $\mathbb{E}[\theta] = \frac{\alpha}{\alpha + \beta}$. Дисперсия: $\text{Var}(\theta) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$

Параметры α и β имеют интуитивный смысл: $\alpha - 1$ — число «псевдо-успехов», $\beta - 1$ — число «псевдо-неудач». При $\alpha = \beta = 1$ — равномерное (полное незнание). При $\alpha = \beta = 2$ — мягкое предположение о «честности» рычага. При больших α, β — распределение концентрируется вокруг $\frac{\alpha}{\alpha + \beta}$.

Сопряжённая пара Beta-Bernoulli

Ключевое свойство Бета-распределения — оно является **сопряжённым априорным** (conjugate prior) к распределению Бернулли.

Байесовское обновление Beta-Bernoulli

Пусть $\theta_k \sim \text{Beta}(\alpha_k, \beta_k)$ (априорное). Наблюдаем n независимых испытаний Бернулли с параметром θ_k : s успехов и $f = n - s$ неудач. Тогда апостериорное распределение:

$$\theta_k \mid (s, f) \sim \text{Beta}(\alpha_k + s, \beta_k + f)$$

Доказательство. По теореме Байеса апостериорная плотность пропорциональна произведению априорной плотности и функции правдоподобия:

$$\begin{aligned} \pi(\theta_k \mid s, f) &\propto \pi(\theta_k) \cdot P(s, f \mid \theta_k) \\ &\propto \theta_k^{\alpha_k-1} (1 - \theta_k)^{\beta_k-1} \cdot \theta_k^s (1 - \theta_k)^f \\ &= \theta_k^{\alpha_k+s-1} (1 - \theta_k)^{\beta_k+f-1} \end{aligned}$$

Это с точностью до константы нормировки есть плотность $\text{Beta}(\alpha_k + s, \beta_k + f)$.

□

Правило обновления элементарно:

- Если успех ($R = 1$): $\alpha_k \rightarrow \alpha_k + 1$
- Если неудача ($R = 0$): $\beta_k \rightarrow \beta_k + 1$

Это **последовательное (онлайн) обновление**: апостериорное после t шагов становится априорным для шага $t + 1$. Именно это свойство делало сопряжённые распределения незаменимыми до эпохи MCMC.

Связь со смешанными распределениями

Из курса: **смешанное распределение** — это распределение, которое получается как взвешенная смесь. Здесь возникает **предсказательное распределение** (predictive distribution) — вероятность следующей награды, усреднённая по апостериорному:

$$\mathbb{P}(R_{n+1} = 1 \mid \mathcal{D}_n) = \int_0^1 \theta \cdot \pi(\theta \mid \mathcal{D}_n) d\theta = \mathbb{E}[\theta \mid \mathcal{D}_n] = \frac{\alpha + s}{\alpha + \beta + n}$$

Это **правило Лапласа** (сглаживание): вместо частоты $\frac{s}{n}$ используем $\frac{\alpha+s}{\alpha+\beta+n}$. При $\alpha = \beta = 1$ получаем $\frac{s+1}{n+2}$ — классическое сглаживание Лапласа.

Алгоритм Сэмплирования Томпсона

Thompson Sampling

Инициализация: для каждого рычага $k = 1, \dots, K$ задаём $\alpha_k = 1, \beta_k = 1$.

На каждом шаге $t = 1, 2, \dots, T$:

1. Для каждого рычага k сэмплируем: $\hat{\theta}_k \sim \text{Beta}(\alpha_k, \beta_k)$
2. Выбираем рычаг с максимальным сэплом: $A_t = \arg \max_k \hat{\theta}_k$
3. Наблюдаем награду $R_t \in \{0, 1\}$
4. Обновляем: $\alpha_{A_t} += R_t, \beta_{A_t} += (1 - R_t)$

Алгоритм поразительно прост: всего 4 строки. Томпсон предложил его в 1933 году для задачи клинических испытаний (какое из двух лечений эффективнее?).

Интуиция: Probability Matching

Почему мы сэмплируем, а не берём просто математическое ожидание $\mathbb{E}[\theta_k] = \frac{\alpha_k}{\alpha_k + \beta_k}$?

Если брать только матожидание, алгоритм будет **слишком жадным** (pure exploitation) и может застрять в локальном оптимуме: если рычаг k случайно дал несколько наград подряд в начале, алгоритм будет выбирать только его, игнорируя остальные.

Сэмплирование вводит **естественный шум для exploration**: рычаг с широким апостериорным (мало данных) будет иногда давать большие сэмплы и выбираться «на пробу».

Свойство. Probability Matching

Вероятность того, что Thompson Sampling выберет рычаг k на шаге t , в точности равна апостериорной вероятности того, что этот рычаг является оптимальным:

$$\mathbb{P}(A_t = k \mid \mathcal{D}_{t-1}) = \mathbb{P}\left(\theta_k = \max_i \theta_i \mid \mathcal{D}_{t-1}\right)$$

Это свойство называется **Probability Matching**. Чем шире апостериорное распределение (меньше уверенности), тем больше дисперсия сэмплов, и тем чаще рычаг выбирается «на пробу». По мере накопления данных дисперсия падает, и алгоритм переходит к exploitation.

Упражнение

Три рычага, 10 шагов

Пусть $K = 3$ рычага с истинными вероятностями $\theta_1^* = 0.3$, $\theta_2^* = 0.7$, $\theta_3^* = 0.5$. Оптимальный рычаг — $k^* = 2$

Начальное состояние: все $\text{Beta}(1, 1)$ — равномерное распределение на $[0, 1]$.

Шаг t	$\hat{\theta}_1$	$\hat{\theta}_2$	$\hat{\theta}_3$	A_t	R_t
1	0.41	0.68	0.55	2	1
2	0.29	0.52	0.71	3	0
3	0.55	0.61	0.38	2	1
4	0.38	0.74	0.44	2	0
5	0.62	0.48	0.39	1	0
6	0.28	0.83	0.51	2	1
7	0.44	0.69	0.48	2	1
8	0.51	0.71	0.52	2	1
9	0.33	0.65	0.60	2	0
10	0.47	0.72	0.55	2	1

После 10 шагов: $\text{Beta}(2, 2)$ для рычага 1 (1 выбор, 0 успехов), $\text{Beta}(7, 3)$ для рычага 2 (7 выборов, 6 успехов), $\text{Beta}(1, 2)$ для рычага 3 (1 выбор, 0 успехов). Алгоритм быстро «нашёл» оптимальный рычаг 2.

Теоретические гарантии

Нижняя граница Лая–Роббинса

В 1985 году Лай и Роббинс доказали фундаментальную нижнюю границу для задачи МАВ — никакой состоятельный алгоритм не может делать лучше:

Теорема (Lai & Robbins, 1985). Нижняя граница regret

Для любого состоятельного алгоритма (то есть такого, что $\mathbb{E}[N_{k(T)}] = o(T^a)$ для любого $a > 0$ и любого k с $\Delta_k > 0$):

$$\liminf_{T \rightarrow \infty} \frac{\mathbb{E}[\text{Regret}(T)]}{\ln T} \geq \sum_{k: \Delta_k > 0} \frac{\Delta_k}{D_{\text{KL}}(\mu_k \parallel \mu^*)}$$

где $D_{\text{KL}}(p \parallel q) = p \ln\left(\frac{p}{q}\right) + (1-p) \ln\left(\frac{1-p}{1-q}\right)$ — дивергенция Кульбака–Лейблера.

Интуиция: KL-дивергенция $D_{\text{KL}}(\mu_k \parallel \mu^*)$ измеряет, насколько легко отличить рычаг k от оптимального k^* по наблюдениям. Чем ближе μ_k к μ^* , тем меньше KL-дивергенция, тем сложнее различить рычаги, и тем больше раз нужно «пробовать» субоптимальный рычаг — это неизбежная цена exploration.

Связь с курсом: KL-дивергенция $D_{\text{KL}}(p \parallel q) = \text{CE}(p \parallel q) - H(p)$ — разность кросс-энтропии и энтропии из лекции 8. Она всегда неотрицательна (неравенство Гиббса) и равна нулю тогда и только тогда, когда $p = q$.

Асимптотическая оптимальность Thompson Sampling

Теорема (Kaufmann, Korda, Munos, 2012). Оптимальность TS

Thompson Sampling с априорным $\text{Beta}(1, 1)$ для Bernoulli-бандита достигает нижней границы Лая–Роббинса:

$$\lim_{T \rightarrow \infty} \frac{\mathbb{E}[\text{Regret}(T)]}{\ln T} = \sum_{k: \Delta_k > 0} \frac{\Delta_k}{D_{\text{KL}}(\mu_k \parallel \mu^*)}$$

Это означает, что Thompson Sampling является **асимптотически оптимальным** — никакой другой алгоритм не может иметь существенно меньший regret в долгосрочной перспективе.

Связи по темам курса

Индекс Гиттинса (Gittins, 1979) — точное оптимальное решение для байесовских бандитов с **дисконтированием** (когда награда в будущем умножается на γ^t , $\gamma < 1$). Для Beta-Bernoulli бандита индекс Гиттинса определяется как:

$$G_k = \sup_{\tau \geq 1} \frac{\mathbb{E} \left[\sum_{t=0}^{\tau-1} \gamma^t R_t \mid \theta_k \sim \text{Beta}(\alpha_k, \beta_k) \right]}{\mathbb{E} \left[\sum_{t=0}^{\tau-1} \gamma^t \mid \theta_k \sim \text{Beta}(\alpha_k, \beta_k) \right]}$$

Thompson Sampling vs. Gittins Index

- **Gittins Index** — точное оптимальное решение при дисконтировании, но вычислительно сложное (NP-hard в общем случае)
- **Thompson Sampling** — вычислительно тривиальное приближение, асимптотически оптимальное при $\gamma \rightarrow 1$
- При $\gamma \rightarrow 1$ оба алгоритма достигают нижней границы Лая–Роббинса
- Thompson Sampling легко обобщается на сложные модели (нелинейные, контекстные), где Gittins Index неприменим

Критерий Кэлли (Kelly, 1956) говорит нам, какую долю капитала f^* ставить при известной вероятности выигрыша p и коэффициенте b : $f^* = p - \frac{q}{b} = p - \frac{1-p}{b}$.

Но что если p неизвестно? Байесовский подход предлагает использовать **predictive distribution** (смешанное распределение по апостериорному):

$$f_{\text{Bayes}}^* = \mathbb{E}[\theta \mid \mathcal{D}] - \frac{1 - \mathbb{E}[\theta \mid \mathcal{D}]}{b} = \frac{\alpha + s}{\alpha + \beta + n} - \frac{\beta + f}{(\alpha + \beta + n) \cdot b}$$

Thompson Sampling элегантно решает проблему неизвестного p в **динамике**: широкое апостериорное распределение (мало данных) приводит к высокой дисперсии сэмплов, что заставляет алгоритм исследовать, прежде чем делать крупные «ставки» на один рычаг.

Замечание. Связь глубже: критерий Кэлли максимизирует $\mathbb{E}[\ln W_T]$ (логарифм капитала) — это задача оптимального управления с известными вероятностями. Thompson Sampling решает аналогичную задачу при **неизвестных** вероятностях, автоматически балансируя между обучением (exploration) и заработком (exploitation).

Критерий Брусса (задача оптимальной остановки) решает вопрос: «когда остановиться и принять решение?» Thompson Sampling решает другой вопрос: «что выбрать на каждом шаге, не останавливаясь?»

Оба используют **обратную индукцию** (backward induction). В критерии Брусса мы вычисляем оптимальную стратегию, идя от последнего шага к первому. В анализе Thompson Sampling regret также анализируется через декомпозицию по шагам.

Ключевое различие: Брусс — **оффлайн** (знаем горизонт T), Thompson Sampling — **онлайн** (адаптируемся по ходу).

Экспоненциальное семейство и общая сопряжённость

Теорема Диаконис–Илвисакер (Diaconis & Ylvisaker, 1979) обобщает Beta-Bernoulli сопряжённость на всё **экспоненциальное семейство**:

Теорема (Diaconis & Ylvisaker, 1979). Общая сопряжённость

Пусть правдоподобие принадлежит экспоненциальному семейству:

$$p(x | \eta) = h(x) \exp(\eta^\top T(x) - A(\eta))$$

где η — натуральный параметр, $T(x)$ — достаточная статистика, $A(\eta)$ — логарифм нормировки. Тогда сопряжённое априорное:

$$\pi(\eta | n_0, t_0) \propto \exp(n_0 t_0^\top \eta - n_0 A(\eta))$$

Апостериорное после n наблюдений с суммой достаточных статистик $\sum T(x_i)$:

$$\pi(\eta | \mathcal{D}) \propto \exp\left((n_0 + n) \left(\frac{n_0 t_0 + \sum T(x_i)}{n_0 + n}\right)^\top \eta - (n_0 + n) A(\eta)\right)$$

то есть параметры обновляются как: $n_0 \rightarrow n_0 + n$, $t_0 \rightarrow \frac{n_0 t_0 + \sum T(x_i)}{n_0 + n}$.

Правдоподобие	Параметр	Сопряжённое	Правило обновления
Bernoulli(θ)	$\theta \in [0, 1]$	Beta(α, β)	$\alpha + = s, \beta + = f$
Normal(μ, σ^2)	$\mu \in \mathbb{R}$	Normal(μ_0, τ^2)	$\mu_0 \rightarrow$ взвеш. среднее
Poisson(λ)	$\lambda > 0$	Gamma(α, β)	$\alpha + = \sum x_i, \beta + = n$
Exponential(λ)	$\lambda > 0$	Gamma(α, β)	$\alpha + = n, \beta + = \sum x_i$
Multinomial(p)	$p \in \Delta^K$	Dirichlet(α)	$\alpha_k + = n_k$

Гауссовские бандиты

Если награды непрерывны и нормально распределены $R_t \mid A_t = k \sim \mathcal{N}(\mu_k, \sigma^2)$ с известной дисперсией, то сопряжённое априорное для μ_k — нормальное: $\mu_k \sim \mathcal{N}(\mu_0, \tau_0^2)$. Апостериорное после n наблюдений со средним $\bar{x}$:

$$\mu_k \mid \mathcal{D} \sim \mathcal{N}\left(\frac{\frac{\mu_0}{\tau_0^2} + n\frac{\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

Thompson Sampling для гауссовских бандитов работает аналогично: сэмплируем $\hat{\mu}_k$ из апостериорного нормального и выбираем $\arg \max_k \hat{\mu}_k$.

Контекстные бандиты и применения

В реальных задачах часто есть **контекст** x_t (характеристики пользователя, время суток и т.д.), и награда зависит от пары (рычаг, контекст). Thompson Sampling обобщается на этот случай через байесовскую линейную регрессию или нейросети с байесовскими весами.

Практические применения:

- **А/В-тестирование:** адаптивное распределение трафика между вариантами сайта (Google Analytics, Netflix). Вместо фиксированного разбиения 50/50 трафик перераспределяется в пользу лучшего варианта по мере накопления данных.
- **Клинические испытания:** исходная мотивация Томпсона (1933) — как распределять пациентов между лечениями, чтобы максимизировать число выздоровевших в ходе самого испытания.
- **Рекомендательные системы:** exploration новых товаров/контента.
- **Онлайн-реклама:** выбор баннера с максимальным CTR.
- **Reinforcement Learning:** posterior sampling для MDP (Strens, 2000).

Список литературы

1. **Thompson W.R.** (1933). On the Likelihood that One Unknown Probability Exceeds Another in View of the Evidence of Two Samples. *Biometrika*, 25(3–4):285–294. <https://doi.org/10.1093/biomet/25.3-4.285>
2. **Gittins J.C.** (1979). Bandit Processes and Dynamic Allocation Indices. *Journal of the Royal Statistical Society, Series B*, 41(2):148–177.
3. **Lai T.L., Robbins H.** (1985). Asymptotically Efficient Adaptive Allocation Rules. *Advances in Applied Mathematics*, 6(1):4–22.
4. **Diaconis P., Ylvisaker D.** (1979). Conjugate Priors for Exponential Families. *The Annals of Statistics*, 7(2):269–281.
5. **Kaufmann E., Korda N., Munos R.** (2012). Thompson Sampling: An Asymptotically Optimal Finite-Time Analysis. *Algorithmic Learning Theory (ALT 2012)*, LNCS 7568:199–213. <https://arxiv.org/abs/1205.4217>
6. **Agrawal S., Goyal N.** (2012). Analysis of Thompson Sampling for the Multi-armed Bandit Problem. *Conference on Learning Theory (COLT 2012)*, JMLR Proceedings 23:39.1–39.26.
7. **Russo D.J., Van Roy B., Kazerouni A., Osband I., Wen Z.** (2018). A Tutorial on Thompson Sampling. *Foundations and Trends in Machine Learning*, 11(1):1–96. https://web.stanford.edu/~bvr/pubs/TS_Tutorial.pdf
8. **Chapelle O., Li L.** (2011). An Empirical Evaluation of Thompson Sampling. *Advances in Neural Information Processing Systems (NeurIPS 2011)*, 24:2249–2257.
9. **Kelly J.L.** (1956). A New Interpretation of Information Rate. *Bell System Technical Journal*, 35(4):917–926.
10. **Cover T.M., Thomas J.A.** (2006). *Elements of Information Theory* (2nd ed.). Wiley-Interscience. [Главы 2, 8 — энтропия и KL-дивергенция]