

1. Задача многоруких бандитов (MAB)

Имеется K «рычагов» (slot machines). На шаге t :

- Выбираем рычаг $A_t \in \{1, \dots, K\}$
- Получаем награду $R_t \sim P_{A_t}$ (неизвестное распределение)

Цель: минимизировать **кумулятивный regret**:

$$\text{Regret}(T) = T \cdot \mu^* - \sum_{t=1}^T \mu_{A_t}, \quad \mu^* = \max_k \mu_k$$

Дилемма: exploration (изучать новые рычаги) vs. exploitation (использовать лучший известный).

2. Алгоритм Томпсона (1933)

Вход: априорные $\pi(\theta_k)$ для каждого рычага k .

На каждом шаге t :

- Сэмплируем $\hat{\theta}_k \sim \pi(\theta_k \mid \mathcal{D}_{t-1})$ для всех k
- Выбираем $A_t = \arg \max_k \hat{\theta}_k$
- Наблюдаем R_t , обновляем апостериорное

Интуиция: действуем оптимально относительно случайно выбранных «убеждений» из апостериорного.

«Probability matching»: рычаг выбирается с вероятностью, что он лучший.

3. Beta-Bernoulli: сопряжённая пара

Модель: $R_t \mid A_t = k \sim \text{Bern}(\theta_k)$, $\theta_k \in [0, 1]$

Априорное: $\theta_k \sim \text{Beta}(\alpha_k, \beta_k)$

Апостериорное (после s успехов, f неудач):

$$\theta_k \mid \mathcal{D} \sim \text{Beta}(\alpha_k + s, \beta_k + f)$$

Почему это работает:

$$\underbrace{\theta^{\alpha-1}(1-\theta)^{\beta-1}}_{\text{prior}} \times \underbrace{\theta^s(1-\theta)^f}_{\text{likelihood}} = \theta^{\alpha+s-1}(1-\theta)^{\beta+f-1}$$

Апостериорное $\in$ то же семейство! Обновление = сложение.

Факт (Diaconis & Ylvisaker, 1979): Для любого экспоненциального семейства $p(x|\theta) = h(x) \exp(\eta(\theta)^T T(x) - A(\theta))$ существует сопряжённое априорное $\pi(\theta) \propto \exp(n_0 t_0^T \eta(\theta) - n_0 A(\theta))$, где n_0 — «псевдо-наблюдения», t_0 — «псевдо-статистика».

Центральная блок-схема: байесовский цикл

Априорное: $\theta_k \sim \text{Beta}(\alpha_k, \beta_k)$

⇓ Сэмплируем $\hat{\theta}_k$ из каждого

Выбор: $A_t = \arg \max_k \hat{\theta}_k$

⇓ Наблюдаем $R_t \in \{0, 1\}$

Обновление: $\alpha_k \leftarrow \alpha_k + R_t, \beta_k \leftarrow \beta_k + (1 - R_t)$

⇓ Апостериорное = новое априорное

Апостериорное: $\theta_k \mid \mathcal{D}_t \sim \text{Beta}(\alpha_k + s_k, \beta_k + f_k)$

↻ Цикл повторяется. По мере $t \rightarrow \infty$: апостериорное концентрируется вокруг θ_k^*

Теорема (Kaufmann, Korda, Munos, 2012): асимптотическая оптимальность

Нижняя граница Лай–Роббинса (1985): для любой состоятельной стратегии:

$$\liminf_{T \rightarrow \infty} \frac{\text{Regret}(T)}{\ln T} \geq \sum_{k: \mu_k < \mu^*} \frac{\mu^* - \mu_k}{D_{\text{KL}}(\mu_k \parallel \mu^*)}$$

Результат: Thompson Sampling с Beta-Bernoulli **достигает** этой границы:

$$\mathbb{E}[\text{Regret}(T)] \leq \sum_{k \neq k^*} \frac{\mu^* - \mu_k}{D_{\text{KL}}(\mu_k \parallel \mu^*)} \cdot \ln T + C$$

где $D_{\text{KL}}(p \parallel q) = p \ln\left(\frac{p}{q}\right) + (1-p) \ln\left(\frac{1-p}{1-q}\right)$ — дивергенция Кульбака–Лейблера.

Связь с курсом: KL-дивергенция из лекции 8 (энтропия) определяет скорость обучения!

Сравнение подходов к MAB

Критерий	Thompson	UCB	Gittins
Парадигма	Байесовская	Частотная	Байесовская
Regret	$O(\ln T)$	$O(\ln T)$	Оптimalен (диск.)
Вычисления	$O(K)$ / шаг	$O(K)$ / шаг	Экспоненц.
Обобщения	Любая модель	Ограничены	Только MAB
Априорное	Нужно	Не нужно	Нужно
А/В тесты	Да (адаптивно)	Да	Сложно
Контекст	Легко	Возможно	Нет

4. Связь с индексом Гиттинса (курс)

Gittins (1979): оптимальная стратегия для дисконтированных бандитов — выбрать рычаг с максимальным **индексом**:

$$G_k = \sup_{\tau \geq 1} \frac{\mathbb{E} \left[\sum_{t=1}^{\tau} \gamma^{t-1} R_t \mid \mathcal{F}_k \right]}{\mathbb{E} \left[\sum_{t=1}^{\tau} \gamma^{t-1} \mid \mathcal{F}_k \right]}$$

Thompson vs Gittins:

- Gittins оптимален при дисконтировании, но NP-hard для вычисления
- Thompson — **приближение**: сэмплирует вместо вычисления индекса
- При $\gamma \rightarrow 1$: оба достигают границы Лай–Роббинса

Из курса: индекс Гиттинса решает «когда переключиться» — TS решает это стохастически.

5. Связь с критерием Кэлли (курс)

Kelly (1956): оптимальная доля ставки $f^* = p - \frac{q}{b}$ при вероятности p .

Проблема: p неизвестно! Байесовское решение:

$$f_{\text{Bayes}}^* = \mathbb{E}[\theta \mid \mathcal{D}] - \frac{1 - \mathbb{E}[\theta \mid \mathcal{D}]}{b}$$

Thompson Sampling **автоматически** учитывает неопределённость в p : широкое апостериорное $\rightarrow$ больше exploration $\rightarrow$ осторожные ставки.

Связь: Kelly = exploitation; TS добавляет exploration через сэмплирование.

6. Связь с методом первого шага

Метод первого шага (курс): $\mathbb{E}[X] = \sum_i \mathbb{E}[X \mid A_1 = i] \mathbb{P}(A_1 = i)$

В Thompson Sampling — **аналогичная декомпозиция**:

$$\mathbb{E}[\text{Regret}(T)] = \sum_{k=1}^K \Delta_k \cdot \mathbb{E}[N_{k(T)}]$$

где $N_{k(T)}$ = число выборов рычага k , $\Delta_k = \mu^* - \mu_k$.

Анализ $\mathbb{E}[N_{k(T)}]$ — через «первый шаг» в цепи Маркова апостериорных!

7. Мах энтропии $\rightarrow$ выбор априорного

Вопрос: какое априорное выбрать для $\theta_k \in [0, 1]$?

Принцип мах энтропии (Jaynes):

$$\max H(\theta) = - \int_0^1 \pi(\theta) \ln \pi(\theta) d\theta$$

при $\int \pi = 1 \rightarrow \pi(\theta) = \text{Uniform}(0, 1) = \text{Beta}(1, 1)$

Неинформативное априорное Джеффриса: $\pi(\theta) \propto \sqrt{I(\theta)} = \text{Beta}(\frac{1}{2}, \frac{1}{2})$

Из курса (лекция 9): мах энтропии при ограничениях $\rightarrow$ экспоненциальное семейство.

Применения: А/В тесты (Google, Netflix); клинические испытания (Thompson, 1933); рекомендации; онлайн-реклама (CTR); RL/MDP (Strens, 2000). **Факт (Chapelle & Li, NeurIPS 2011):** TS превосходит UCB и ε -greedy эмпирически.

Экспоненциальное семейство и сопряжённость

$p(x|\theta) = h(x) \exp(\eta^T T(x) - A(\theta))$. Сопряжённое: $\pi(\eta) \propto \exp(n_0 t_0^T \eta - n_0 A(\eta))$. Обновление: $n_0 \rightarrow n_0 + n$, $t_0 \rightarrow \frac{n_0 t_0 + \sum T(x_i)}{n_0 + n}$. Замкнутая форма!

Смешанные распределения (курс)

Predictive distribution: $p(x|\mathcal{D}) = \int p(x|\theta) \pi(\theta|\mathcal{D}) d\theta$ — **смесь** по апостериорному. Для Beta-Bernoulli: $\mathbb{P}(R = 1|\mathcal{D}) = \frac{\alpha+s}{\alpha+\beta+n}$ — среднее апостериорного.

Критерий Брусса (курс) vs TS

Брусс: оптимальная остановка, «когда остановиться». TS: «что выбрать на каждом шаге». Оба используют обратную индукцию. TS — онлайн-версия: не останавливаемся, а **адаптируемся**.

Псевдокод (3 строки!)

for t = 1, 2, ..., T:
 sample theta from Beta
 play k = argmax theta
 update alpha, beta